

Machine Learning pour la lutte contre la fraude

Voir grand et tout petit, mais juste

Theo Lopes Quintas

BPCE Payment Services,
Université Paris Dauphine

22 juin 2026

Contexte

Le paiement et la fraude en France

La banque de France réalise chaque année un rapport sur l'évolution des paiements et de la fraude associée. Ce rapport est également réalisé au niveau Européen. Quelques éléments du rapport 2025 sur les paiements de l'année 2024 :

- ▶ La carte reste le moyen de paiement le plus utilisé en France : 62% des paiements
- ▶ Le paiement par chèque est en recul continue en France (-10/-15% par ans)
- ▶ Le virement instantané continue de se déployer fortement : 10% des virements sont instantanés en 2024
- ▶ Le montant total de la fraude déclaré en France est de 1.189 milliards d'euros
 - 44% pour la carte - vente à distance, proximité et retrait
 - 30% pour le virement
 - 23% pour le chèque
- ▶ Le virement instantané est un canal préféré par les fraudeurs
 - Taux de fraude virement SEPA (hors instantané) : 0.0019%
 - Taux de fraude virement SEPA instantané : 0.0457%
 - Taux de fraude carte : 0.053%

Contexte

Le paiement et la fraude en France

Le rapport pour les paiements de 2025 sera disponible en septembre 2026. Voici les quelques tendances que l'on observe :

- ▶ Sur le premier semestre de 2025 :
 - 62 millions de paiement carte par jour
 - 17 millions de virements par jour
 - 1.9 millions de chèques par jour
- ▶ En terme de fraude, **chaque heure** au premier semestre de 2025, il y a eu 851 fraudes en moyennes pour 142 milles euros
- ▶ Le montant de fraude virement dépasse pour la première fois le montant de la fraude carte, porté par l'évolution rapide du virement instantané


Avec le déploiement de la solution de paiement WERO par le scheme EPI, le virement instantané s'installe comme un point d'attention particulier dans la lutte contre la fraude

Contexte

Formalisation du problème Machine Learning

Dans le cadre supervisé, nous avons accès à un dataset $\mathcal{D}$ défini comme :


$$\mathcal{D} = \left\{ (x_i, y_i) \mid \forall i \leq n, x_i \in \mathbb{R}^{d'}, y_i \in \mathcal{Y} \right\} \quad (1)$$



Avec $\mathcal{Y} \subseteq \mathbb{R}$ pour un problème de régression et $\mathcal{Y} \subset \mathbb{N}$ dans le cadre d'une classification. Les problèmes de Machine Learning supervisés peuvent souvent s'écrire sous la forme d'une optimisation d'une fonction de perte $\mathcal{L} : \mathbb{R}^d \times \mathcal{M}_{n,d'} \times \mathbb{R}^n \rightarrow \mathbb{R}_+$ comme :

Vecteur des paramètres optimaux

$$\theta^* = \arg \min_{\theta \in \mathbb{R}^d} \mathcal{L}(\theta; X, y)$$



Dans la suite, pour simplifier les notations, nous omettrons la dépendance de $\mathcal{L}$ en X et y . Notons qu'en général, nous avons $d \neq d'$ et dans le cas du deep learning, très souvent $d \gg d'$.

En résumé

- 1 Contexte 1
 - 1.1 Le paiement et la fraude en France 1
 - 1.2 Machine Learning 3
- 2 Hyper déséquilibre de classe : voir tout petit 5
- 3 Travail en grande dimension : voir grand 15
- 4 Calibration : voir juste 21
- 5 Que dit la recherche ? 25

Hyper déséquilibre de classe : voir tout petit

Sur-échantillonnage aléatoire

Une première méthode pour équilibrer le dataset est de dupliquer aléatoirement des observations de la classe minoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .

Hyper déséquilibre de classe : voir tout petit

Sur-échantillonnage aléatoire

Une première méthode pour équilibrer le dataset est de dupliquer aléatoirement des observations de la classe minoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .




Figure – Illustration du sur-échantillonnage

Hyper déséquilibre de classe : voir tout petit

Sur-échantillonnage aléatoire

Une première méthode pour équilibrer le dataset est de dupliquer aléatoirement des observations de la classe minoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .




Figure – Illustration du sur-échantillonnage

Hyper déséquilibre de classe : voir tout petit

Sur-échantillonnage aléatoire

Une première méthode pour équilibrer le dataset est de dupliquer aléatoirement des observations de la classe minoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .




Figure – Illustration du sur-échantillonnage

Figure – Évolution de la taille du dataset final en fonction de la proportion finale de la classe minoritaire

Hyper déséquilibre de classe : voir tout petit

Sur-échantillonnage aléatoire

$$n_f = n_i \frac{1 - p_i}{1 - p_f}$$

Diagram illustrating the formula for the final dataset size (n_f) after over-sampling, derived from the initial dataset size (n_i), initial minority class proportion (p_i), and final minority class proportion (p_f).

Labels in the diagram:

- Taille initiale du dataset (Initial dataset size) points to n_i .
- Proportion de la classe minoritaire initiale (Initial minority class proportion) points to p_i .
- Taille finale du dataset (Final dataset size) points to n_f .
- Proportion de la classe minoritaire finale (Final minority class proportion) points to p_f .

(Over sampling)

Exercice 1 (Paramétrer un arbre)

Nous avons accès à un dataset d'un million de lignes avec une proportion initiale de la classe minoritaire de 1%. Après avoir équilibré le dataset avec du sur-échantillonnage, vous utilisez un arbre ou une méthode à base d'arbres.

1. Combien y avait-il d'observations de la classe minoritaire au début ? A la fin ?
2. En moyenne, combien de fois une même observation de la classe minoritaire est présente dans le dataset final ?
3. Comment ajuster en conséquence les paramètres d'un arbre ?

Hyper déséquilibre de classe : voir tout petit

Sous-échantillonnage aléatoire

Une deuxième méthode pour équilibrer le dataset est de supprimer aléatoirement des observations de la classe majoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .

Hyper déséquilibre de classe : voir tout petit

Sous-échantillonnage aléatoire

Une deuxième méthode pour équilibrer le dataset est de supprimer aléatoirement des observations de la classe majoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .




Figure – Illustration du sous-échantillonnage

Hyper déséquilibre de classe : voir tout petit

Sous-échantillonnage aléatoire

Une deuxième méthode pour équilibrer le dataset est de supprimer aléatoirement des observations de la classe majoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .

$$n_f = n_i \frac{p_i}{p_f}$$

Taille initiale du dataset

Proportion de la classe minoritaire initiale

Taille finale du dataset

(Under sampling)




Figure – Illustration du sous-échantillonnage

Hyper déséquilibre de classe : voir tout petit

Sous-échantillonnage aléatoire

Une deuxième méthode pour équilibrer le dataset est de supprimer aléatoirement des observations de la classe majoritaire, jusqu'à ce qu'on atteigne la proportion de la classe minoritaire voulue p_f .





Figure – Illustration du sous-échantillonnage

Figure – Évolution de la taille du dataset final en fonction de la proportion finale de la classe minoritaire

Hyper déséquilibre de classe : voir tout petit

Sous-échantillonnage aléatoire



Exercice 2 (Conserver la représentativité)

Nous avons accès à un dataset d'un million de lignes avec une proportion initiale de la classe minoritaire de 1%. Après avoir équilibré le dataset avec du sous-échantillonnage, vous explorez les données.

1. Combien y avait-il d'observations de la classe majoritaire au début ? A la fin ?
2. Quelle est la probabilité qu'une observation de la classe majoritaire soit présente dans le dataset final ?
3. Supposons qu'un groupe d'observations (par exemple les transactions par téléphone ou mail) représente 5% des observations de la classe majoritaire. Quelle est la probabilité qu'il ne soit plus présent dans le dataset final ?
4. Quel problème cela induit-il sur le modèle à construire en production ? Comment s'en prémunir ?

Hyper déséquilibre de classe : voir tout petit


SMOTE : une approche prometteuse

Les deux précédentes approches dupliquent ou suppriment des observations du dataset. On peut explorer la possibilité de *créer* des observations synthétiques : c'est l'objet de SMOTE.

Hyper déséquilibre de classe : voir tout petit

SMOTE : une approche prometteuse

Les deux précédentes approches dupliquent ou suppriment des observations du dataset. On peut explorer la possibilité de *créer* des observations synthétiques : c'est l'objet de SMOTE.




(a) Sélection aléatoire d'une observation de la classe minoritaire

Figure – Fonctionnement de SMOTE


Hyper déséquilibre de classe : voir tout petit

SMOTE : une approche prometteuse

Les deux précédentes approches dupliquent ou suppriment des observations du dataset. On peut explorer la possibilité de *créer* des observations synthétiques : c'est l'objet de SMOTE.



(a) Sélection aléatoire d'une observation de la classe minoritaire



(b) Identification des $k=5$ voisins les plus proches

Figure – Fonctionnement de SMOTE

Hyper déséquilibre de classe : voir tout petit

SMOTE : une approche prometteuse

Les deux précédentes approches dupliquent ou suppriment des observations du dataset. On peut explorer la possibilité de *créer* des observations synthétiques : c'est l'objet de SMOTE.




Figure – Fonctionnement de SMOTE

Hyper déséquilibre de classe : voir tout petit

SMOTE : observations synthétiques ambiguës

SMOTE et One Hot Encoding

SMOTE est une méthode qui ne travaille que les datasets avec des données quantitatives. Elle fonctionne donc théoriquement sur des informations issues d'un One Hot Encoding mais on ne doit pas l'utiliser en pratique : cela n'a aucun sens. Il faut exploiter une variante de SMOTE : SMOTE-NC pour pouvoir traiter des données qualitatives.

Soit $\mathcal{D}$ un dataset comme défini dans (1) dont on reprend les notations, et $\mathcal{D}^-$ le dataset contenant uniquement les observations de la classe majoritaire. On note $n^- = \#\mathcal{D}^-$.

Soit $\tilde{x}$ un point synthétique généré par l'algorithme SMOTE. On dit que $\tilde{x}$ est un **point ambigu** si

$\min_{x \in \mathcal{D}^-} \|\tilde{x} - x\| \leq \delta$ pour $\delta \geq 0$ un paramètre fixé.

On peut montrer, sous l'hypothèse que $\mathcal{D} \sim \mathcal{N}(0_d, I_d)$, que :

$$\mathbb{P} \left(\min_{x \in \mathcal{D}^-} \|\tilde{x} - x\| \leq \delta \right) = 1 - \left(1 - \int_0^{\frac{\delta^2}{2}} \frac{t^{\frac{d}{2}-1} e^{-\frac{t}{2}}}{2^{\frac{d}{2}} \Gamma\left(\frac{d}{2}\right)} dt \right)^{n^-}$$

Hyper déséquilibre de classe : voir tout petit

SMOTE : observations synthétiques ambiguës - observation sur un dataset réel

Nous souhaitons appliquer cela à un dataset de 20 millions de lignes ayant 1% de déséquilibre.

Déséquilibre final (%)	Observation synthétique ambiguë (%)	Taille du dataset final (en millions)
1	0	20.000
2	39.29	20.204
5	62.86	20.842
10	70.72	22.000
20	74.65	24.750
30	75.96	28.285
40	76.61	33.000
50	77.01	39.600

Table – Évolution de la proportion d’observation synthétique ambiguë et de la taille du dataset final en fonction de la proportion de déséquilibre souhaité

Nous avons fixé la valeur de δ comme le quantile à 0.5% de la loi du χ^2 induite par le dataset.

Hyper déséquilibre de classe : voir tout petit

SMOTE : observations synthétiques ambiguës

$$\mathbb{P} \left(\min_{x \in \mathcal{D}^-} \|\tilde{x} - x\| \leq \delta \right) = 1 - \left(1 - \int_0^{\frac{\delta^2}{2}} \frac{t^{\frac{d}{2}-1} e^{-\frac{t}{2}}}{2^{\frac{d}{2}} \Gamma\left(\frac{d}{2}\right)} dt \right)^{n^-}$$

Exercice 3 (Inducteurs d'observations synthétiques ambiguës)

1. Étudier le comportement asymptotique selon δ . Interpréter.
2. Calculer $\lim_{n^- \rightarrow +\infty} \mathbb{P} \left(\min_{x \in \mathcal{D}^-} \|\tilde{x} - x\| \leq \delta \right)$ et commentez.
3. Que peut-on dire de l'évolution de la probabilité selon la dimension du dataset ?

Hyper déséquilibre de classe : voir tout petit

En résumé

- ▶ L'hyper déséquilibre de classe introduit de nombreux challenges et exacerbe certains phénomènes classiques comme le drift par exemple.
- ▶ Les solutions théoriques sont à explorer et à adapter à chaque cas d'usage. Il est possible qu'aucune ne fonctionne.

En résumé


1	Contexte	1
2	Hyper déséquilibre de classe : voir tout petit	5
2.1	Sur-échantillonnage aléatoire	5
2.2	Sous-échantillonnage aléatoire	7
2.3	SMOTE	9
3	Travail en grande dimension : voir grand	15
4	Calibration : voir juste	21
5	Que dit la recherche ?	25

Travail en grande dimension : voir grand

Motivation

*Tant que vous ne m'aurez pas approuvé, je ne puis
que dire : je le vois mais je ne le crois pas.*

— Georg Cantor (1877)



Travail en grande dimension : voir grand

Hypersphère



(a) En dimension 1, volume = 2


Figure — Représentation et volume d'une hypersphère de rayon 1 dans 3 espaces de dimensions différentes

Travail en grande dimension : voir grand

Hypersphère




(a) En dimension 1, volume = 2



(b) En dimension 2, volume = π

Figure – Représentation et volume d'une hypersphère de rayon 1 dans 3 espaces de dimensions différentes



(b) Avec la norme 2


Figure – Représentation d'une hypersphère de rayon 1 en dimension 2 pour 3 normes différentes

Travail en grande dimension : voir grand

Hypersphère




(a) En dimension 1, volume = 2




(b) En dimension 2, volume = π

Figure – Représentation et volume d'une hypersphère de rayon 1 dans 3 espaces de dimensions différentes



(a) Avec la norme 1



(b) Avec la norme 2



(c) Avec la norme infinie


Figure – Représentation d'une hypersphère de rayon 1 en dimension 2 pour 3 normes différentes

Travail en grande dimension : voir grand


Hypersphère



(a) En dimension 1, volume = 2




(b) En dimension 2, volume = π




(c) En dimension 3, volume = $\frac{4}{3}\pi$

Figure – Représentation et volume d'une hypersphère de rayon 1 dans 3 espaces de dimensions différentes



(a) Avec la norme 1



(b) Avec la norme 2



(c) Avec la norme infinie

Figure – Représentation d'une hypersphère de rayon 1 en dimension 2 pour 3 normes différentes

Travail en grande dimension : voir grand

Volume d'une hypersphère

On appelle *boule* ou hypersphère l'objet défini par :

$$B_n^p(R) = \{u \in \mathbb{R}^n, \|u\|_p^p \leq R^p\}$$

Et son volume par :

$$V_n^p(R) = \int_{B_n^p(R)} \bigotimes_{i=1}^n dx_i$$

Proposition 1 (Volume d'une hypersphere)

Avec les notations précédentes, on a :

$$\begin{aligned} \forall R > 0, \forall n \geq 2, \forall p \geq 1, \quad V_n^p(R) &= \frac{\left(2R\Gamma\left(\frac{1}{p} + 1\right)\right)^n}{\Gamma\left(\frac{n}{p} + 1\right)} \\ &\sim \sqrt{\frac{p}{2\pi n}} \left[2R\Gamma\left(\frac{1}{p} + 1\right) \left(\frac{pe}{n}\right)^{\frac{1}{p}}\right]^n \end{aligned}$$

Avec la fonction Γ définie comme :

$$\Gamma(x) = \int_0^{+\infty} e^{-t} t^{x-1} dt$$

Travail en grande dimension : voir grand

Concentration dans une hypersphère

On rappelle que :

$$\forall R > 0, \forall n \geq 2, \forall p \geq 1, \quad V_n^p(R) = \frac{\left(2R\Gamma\left(\frac{1}{p} + 1\right)\right)^n}{\Gamma\left(\frac{n}{p} + 1\right)}$$

Exercice 4 (Concentration dans l'hypersphère)

Soit $\varepsilon > 0$. On considère une hypersphère de rayon R . Montrer que :

$$\frac{V_n^p(R - \varepsilon)}{V_n^p(R)} = \left(1 - \frac{\varepsilon}{R}\right)^n$$

Travail en grande dimension : voir grand

En résumé


- ▶ Le travail en grande dimension exacerbe l'ensemble des phénomènes présentés jusqu'ici : hyper-déséquilibre ou drift par exemple.
- ▶ Le travail sur la qualité des informations transmises à un modèle ainsi que son architecture est une partie de la réponse à ces problèmes.

En résumé


1	Contexte	1
2	Hyper déséquilibre de classe : voir tout petit	5
3	Travail en grande dimension : voir grand	15
4	Calibration : voir juste	21
5	Que dit la recherche ?	25

Calibration : voir juste

Parfaite calibration



(a) Prédicteur trop confiant et pas assez confiant



(b) Prédicteur non parfaitement calibré


Figure – Comparaison de prédicteurs par rapport à un prédicteur parfaitement calibré (en pointillés)

Calibration : voir juste


Comment induire la calibration ?

Properly regularized logistic regression is well calibrated by default thanks to the use of the log-loss

— Guide utilisateur scikit-learn (2007)



(a) Meilleur modèle obtenu



(b) Diagramme de calibration

Figure — Régression logistique pour la distribution $(x, y) \sim \mathcal{D}$ avec $y = 0$ pour $x \sim \mathcal{U}([-3, 1])$ et $y = 1$ pour $x \sim \mathcal{U}([-1, 3])$

Calibration : voir juste

En résumé

- ▶ La calibration est souhaitable pour tous les modèles destinés à un usage professionnel.
- ▶ Un des moyens de l'induire est de travailler avec des modèles suffisamment puissants pour qu'il *s'auto-calibre* ou d'exploiter un traitement du score après son entraînement.

En résumé

- 1 Contexte 1
- 2 Hyper déséquilibre de classe : voir tout petit 5
- 3 Travail en grande dimension : voir grand 15
- 4 **Calibration : voir juste 21**
- 5 Que dit la recherche ? 25

Que dit la recherche ?

Utiliser l'accuracy

[Luo et al., 2025] affiche un abstract prometteur avec une **accuracy** de 98% pour le problème suivant :

A dataset of 2,840,000 transactions was collected over 14 days from major platforms such as Amazon, involving approximately 2,000 U.S.-based consumers and 30 merchants. With fewer than 6000 fraudulent instances, the dataset represents a highly imbalanced scenario.

Quand on observe les résultats affiché :

category	Precision	Recall	F1-Score	Support
0 (Non-Fraud)	0.98	1.00	0.99	1239159
1 (Fraud)	1.00	0.05	0.09	33365
Accuracy			0.98	1272524
Macro Avg	0.99	0.52	0.54	1272524
Weighted Avg	0.98	0.98	0.96	1272524

Table – GCN model detailed result index

		Predicted label	
		0	1
True label	0	1239155	31726
	1	4	1639

Table – Confusion Matrix

Que dit la recherche ?

Persister avec SMOTE

[Almalki and Masud, 2025] et [Moradi et al., 2025] proposent deux approches très similaires sur le même dataset. On peut noter dans les deux cas la même stratégie de découpage du dataset et de la gestion du déséquilibre :

*To balance the training data, we applied the Synthetic Minority Over-sampling Technique (**SMOTE**), which generates synthetic minority-class examples. After applying SMOTE, the training set had an approximately equal distribution of fraud and non-fraud samples [...]. We then **split** the dataset into training and testing subsets (80% train, 20% test), ensuring that the model's performance would be evaluated on unseen (imbalanced) test data.*

Que dit la recherche ?

Essayer les Transformers

Dans l'optique de tester les transformers dans le cadre de la détection de fraude, [Aminian et al., 2025] teste un modèle type **Transformers** contre la baseline des méthodes traditionnelles. On note en particulier :

*The fraud rate in the test data is around 43% ; this rate does not represent the fraud rate in the whole dataset but is instead obtained through **undersampling** non-fraud cases*

En résumé

1	Contexte	1
2	Hyper déséquilibre de classe : voir tout petit	5
3	Travail en grande dimension : voir grand	15
4	Calibration : voir juste	21
5	Que dit la recherche ?	25

Bibliographie I

-  [Almalki, F. and Masud, M. \(2025\).](#)
Financial fraud detection using explainable ai and stacking ensemble methods.
arXiv preprint arXiv :2505.10050.
-  [Aminian, G., Elliott, A., Li, T., Wong, T. C. H., Dehon, V. C., Szpruch, L., Maple, C., Read, C., Brown, M., Reinert, G., et al. \(2025\).](#)
Fraudtransformer : Time-aware gpt for transaction fraud detection.
arXiv preprint arXiv :2509.23712.
-  [Luo, R., Wang, N., and Zhu, X. \(2025\).](#)
Fraud detection and risk assessment of online payment transactions on e-commerce platforms based on llm and gcn frameworks.
arXiv preprint arXiv :2509.09928.
-  [Moradi, F., Tarif, M., and Homaei, M. \(2025\).](#)
Robust fraud detection with ensemble learning : A case study on the ieee-cis dataset.
Preprint.